
INTELIGENCIA ARTIFICIAL - 2026

PRIMER PROYECTO EVALUATIVO

Algoritmos Genéticos

03 Diseño de Parques Eólicos de Energía

ALUMNOS

Botha, Ana Josefina
Lang, Carlos
Vidal, Facundo
Zarate, Guido Mateo B.

FECHA DE ENTREGA

18/05

Introducción.....	3
Algoritmo Genético.....	3
AG en el Problema del Parque Eólico.....	3
Espacio de búsqueda inmensamente grande.....	3
No-linealidad e interdependencia de variables (Por Efecto Estela).....	3
Objetivo del Proyecto.....	4
Definición del Problema.....	4
Diseño del Algoritmo Genético.....	4
Representación Cromosómica.....	4
Genotipo.....	4
Fenotipo.....	4
Población Inicial.....	5
Operadores Genéticos.....	5
Selección.....	5
Cruce.....	5
Mutación.....	5
Reemplazo generacional.....	6
Criterio de parada.....	6
Resultado y Discusión.....	6
Resultado.....	6
Análisis de Convergencia.....	7
Análisis de Parámetros.....	7
Evaluación del Desempeño Generacional.....	8
Evaluación del Desempeño Temporal.....	8
Gráficos Estadísticos.....	9
Boxplot.....	9
Gráficos Comparativos de Generaciones y Tiempo.....	10
Discusión.....	11
Conclusión.....	11

Introducción

Algoritmo Genético

Un algoritmo genético (o AG) es una variante de la búsqueda de haz estocástica en la que los estados sucesores se generan combinando dos estados padres, más que modificar un solo estado (mutación). La analogía a la selección natural es la misma que con la búsqueda de haz estocástica, excepto que ahora tratamos con reproducción sexual más que con la reproducción asexual.

La variante búsqueda de haz estocástica, en vez de elegir los k mejores del conjunto de sucesores candidatos, la búsqueda de haz estocástica escoge a k sucesores aleatoriamente, con la probabilidad de elegir a un sucesor como una función creciente de su valor. La búsqueda de haz estocástica muestra algún parecido con el proceso de selección natural, por lo cual los «sucesores» (descendientes) de un «estado» (organismo) pueblan la siguiente generación según su «valor» (idoneidad o salud).

AG en el Problema del Parque Eólico

Espacio de búsqueda inmensamente grande

El problema plantea ubicar hasta 25 molinos en una grilla discreta de 20×20 . Esto significa que tenemos 400 celdas posibles para ubicar 25 elementos. Si intentáramos calcular todas las combinaciones posibles mediante fuerza bruta para encontrar la configuración perfecta, estaríamos lidiando con combinaciones de 400 elementos tomados de a 25.

El resultado de esa operación matemática es un número con más de 40 ceros ($C(400, 25)$ aprox. 6.9×10^{42} combinaciones). Es un espacio de búsqueda tan masivo que es computacionalmente imposible de evaluar uno por uno. Los Algoritmos Genéticos son ideales aquí porque no necesitan evaluar cada posibilidad; en su lugar, exploran el espacio de manera inteligente y paralela mediante una población de soluciones.

No-linealidad e interdependencia de variables (Por Efecto Estela)

El problema no es lineal. Esto quiere decir que la energía total del parque no es simplemente la suma de la energía individual de 25 molinos aislados. Debido a las restricciones del efecto estela (que reduce un 8%), la "ganancia" de ubicar un molino en una celda depende completamente de qué haya en las celdas vecinas.

Esta interdependencia crea lo que se llama un landscape muy "rugoso", lleno de óptimos locales. Si se usaran algoritmos de búsqueda local que evalúan un solo estado a la vez (como Hill Climbing), el algoritmo se quedaría atascado rápidamente en una configuración que parece buena, pero que no es la mejor. El Algoritmo Genético, al usar operadores de cruce y mutación, tiene la capacidad de dar "saltos" en ese paisaje y escapar de esos óptimos locales para acercarse al óptimo global.

Objetivo del Proyecto

El objetivo es **maximizar** la sumatoria de las potencias generadas por los molinos, teniendo en cuenta su posición por el efecto estela.

Definición del Problema

Se solicita **ubicar** molinos eólicos en una grilla discreta de 20 x 20 para **maximizar la energía producida**, considerando un viento constante de 12m/s con dirección norte y restricciones por efecto estela en las direcciones de Norte a Sur (3 celdas) y de Este a Oeste (3 celdas), considerando una cantidad máxima de molinos $K = 25$ molinos.

La función **fitness** a tener en cuenta es la siguiente:

$$Z = \sum P_i \text{Base} \cdot \max(0, 1 - \beta \cdot \text{wake}(i,j))$$

En la cual la potencia base del molino (aproximadamente 2,13 MW) es afectada por la cantidad de molinos en su zona de efecto estela ($\text{wake}(i,j)$) suponiendo que este efecto reduce un $\beta = 0,08$ la energía producida.

Cabe aclarar que el óptimo global es conocido, teniendo en cuenta la cantidad máxima de molinos y su energía tope, se llega a lo siguiente:

$$Z_{\max} = 25 \times 2,13 \text{ MW} = 53,25 \text{ MW}$$

Diseño del Algoritmo Genético

Representación Cromosómica

Genotipo

Se utilizará una representación entera basada en coordenadas. Cada cromosoma estará compuesto por un vector de números enteros que representan los pares de coordenadas (x,y) de los molinos. Cada gen tomará un valor entero entre 0 y 19 (posiciones de la matriz).

Fenotipo

Para el cálculo de la función objetivo (fitness), este genotipo se decodificará en una matriz binaria bidimensional de 20 x 20. En esta matriz, un valor de 'M' indicará la presencia de un molino en esa coordenada, y un '.' un espacio vacío, permitiendo mapear fácilmente las interferencias físicas por el efecto estela.

Población Inicial

Si la población es muy pequeña (ej. 10 o 20), el algoritmo tiene poca "diversidad genética". Va a converger muy rápido, pero es casi seguro que se quede estancado en un

extremo local. Si la población es excesivamente grande (ej. 1000), el espacio de búsqueda se explora a fondo, pero el costo computacional por generación se vuelve muy alto, haciendo que el programa tarde demasiado en ejecutarse. Por lo que una población entre 100 y 200 individuos puede ser lo mejor.

Para crear esta población se empleará el método de generación aleatoria controlada para la población inicial, propio de la librería. Este seleccionará aleatoriamente las 25 coordenadas (x,y) dentro de la grilla de 20x20 para cada individuo de la población inicial.

Operadores Genéticos

Selección

Para determinar qué individuos tendrán la oportunidad de reproducirse, se implementará el método de **Selección por Torneo**. En cada iteración, se elegirá un subconjunto aleatorio de individuos (por ejemplo, $K=3$) y el que posea el mejor valor de fitness será seleccionado como padre.

En el problema del parque eólico, el efecto estela genera un "landscape" con muchos óptimos locales. Si usáramos el método de la Ruleta (Proportional Selection), las primeras soluciones decentes ganarían demasiada probabilidad de selección y dominarían la población rápidamente, pudiendo estancar el algoritmo (convergencia prematura). El torneo mantiene una presión selectiva constante pero preserva mejor la **diversidad genética**, permitiendo que el algoritmo siga explorando el mapa.

Cruce

La recombinación del material genético se realizará mediante un **Crossover de Dos Puntos**. Se seleccionarán dos puntos de corte aleatorios en los cromosomas de los padres elegidos. Los genes (coordenadas) que se encuentren entre esos dos puntos se intercambiarán para generar la descendencia.

Dado que nuestro cromosoma es un vector de 50 números enteros (que representan los 25 pares de coordenadas), el cruce de dos puntos puede permitir heredar "bloques" enteros de molinos bien posicionados de un padre, y combinarlos con otro bloque exitoso del otro padre. Es menos disruptivo que el cruce uniforme, el cual mezclaría todo aleatoriamente, y permite conservar estructuras espaciales que hayan demostrado un buen rendimiento en el cálculo del fitness.

Mutación

Se aplicará una Mutación Aleatoria con una probabilidad baja (tasa de mutación entre 5% y 10%). Cuando un gen (x o y) deba mutar, su valor actual será reemplazado por un nuevo número entero aleatorio dentro del espacio de genes permitido (de 0 a 19).

La mutación es crucial para inyectar nuevo material genético y **descubrir posiciones** en la grilla que el cruce por sí solo no alcanzaría. Se mantiene una probabilidad baja para intentar no destruir las buenas configuraciones existentes.

Reemplazo generacional

Se implementará una política de reemplazo generacional con **Elitismo** (Gap Generacional). Este mecanismo asegura que un porcentaje de los mejores individuos de la generación actual pasen directamente y sin sufrir alteraciones a la siguiente generación. Esto garantiza que la curva de convergencia sea monotónica (el mejor fitness histórico nunca decrece) evitando la pérdida de soluciones óptimas descubiertas.

Criterio de parada

Convergencia al Óptimo Global: Siendo matemáticamente factible ubicar 25 molinos en la grilla de 20x20 sin que sus áreas de estela se solapen, el algoritmo detendrá su ejecución inmediatamente si alguna solución alcanza el fitness máximo teórico de 53.25 MW (100% de eficiencia), ya que no existe mejora posible a partir de ese punto.

Límite de generaciones: Se alcanzará un número máximo de generaciones (ej. N=500), garantizando un límite en el tiempo de cómputo.

Estabilidad de la aptitud: El algoritmo se detendrá anticipadamente si el valor del mejor fitness de la población no muestra mejoras significativas durante una ventana consecutiva de generaciones (ej. 50 generaciones sin cambios).

Resultado y Discusión


Resultado

En la primera fase de experimentación (Instancia 1), se evaluó el comportamiento del algoritmo utilizando la configuración de parámetros base. El resultado inicial más destacable es la obtención de un **Hit Rate del 100%** a lo largo de las 30 ejecuciones independientes, lo que da un indicio de un buen diseño cromosómico y de la función de fitness. Junto a esta eficacia, el modelo demostró una buena estabilidad estocástica, dado el carácter probabilístico intrínseco de los algoritmos genéticos, se analizó la dispersión de los resultados mediante la desviación estándar, la cual se situó en 4.1 generaciones, arrojando un coeficiente de variación aproximado de 45%. Para una metaheurística de este tipo, esta métrica se entiende como una estabilidad operativa normal y aceptable; el comportamiento del algoritmo resulta “predecible”, logrando que la gran mayoría de sus ejecuciones converjan de manera exitosa entre la quinta y la decimotercera generación. Finalmente, el tiempo de ejecución promedio por cada iteración fue de apenas 0.186 segundos, lo que evidencia un bajo costo computacional en la resolución de las penalizaciones por efecto estela mediante la evaluación matricial.

Análisis de Convergencia

La velocidad de convergencia es notablemente alta, requiriendo un **promedio de tan solo 9.0 generaciones** para resolver el problema. Se registró un caso atípico de éxito en la iteración mínima (1 generación), lo cual no es atribuible a la presión evolutiva, sino a la

aleatoriedad de los individuos iniciales y a la gran cantidad de configuraciones que pueden resolver el problema.



El gráfico revela que el mejor fitness histórico de la población (representado por la curva superior) parte de un valor inicial elevado, cercano a los 52.75 MW. Esto subraya la cantidad de espacio disponible para la cantidad de molinos a colocar. A partir de allí, gracias a la política de reemplazo con elitismo, el mejor desempeño se mantiene estrictamente monótono creciente, asegurando que las disposiciones espaciales más eficientes de los molinos no se degraden por mutaciones desfavorables. Es particularmente interesante observar el comportamiento en forma de meseta que ocurren, estos estancamientos temporales representan óptimos locales donde el algoritmo debió iterar múltiples combinaciones genéticas para reubicar los últimos molinos sin generar nuevas penalizaciones por efecto estela, logrando finalmente el salto al óptimo global de 53.25 MW en la novena iteración. De manera simultánea, la curva del fitness promedio de toda la población exhibe una tendencia ascendente sostenida. Este ascenso generalizado, acompañado por la banda de desviación estándar constante, evidencia que el operador de selección por torneo cumple su propósito al guiar a toda la masa poblacional hacia configuraciones de mayor rendimiento energético, sin sacrificar prematuramente la diversidad genética necesaria para la exploración del espacio de búsqueda.

Análisis de Parámetros

Con el propósito de evaluar la robustez, el comportamiento dinámico y la sensibilidad del algoritmo genético propuesto ante variaciones en sus hiperparámetros, se diseñó un estudio experimental basado en la evaluación de tres instancias diferenciadas de configuración en PyGAD. Para mitigar el impacto de la estocasticidad propia de los operadores evolutivos y obtener representatividad estadística, cada una de estas instancias fue ejecutada en treinta corridas independientes, consolidando un banco de pruebas de noventa ejecuciones totales.

Las variables estructurales del problema permanecieron invariables en los tres escenarios: la arquitectura cromosómica se definió mediante 50 genes, representativos de las coordenadas espaciales de 25 aerogeneradores dentro de una grilla discreta de 20 por

20 unidades. Los operadores genéticos seleccionados comprendieron la selección por torneo con un parámetro K igual a 3, cruce de dos puntos y una probabilidad de mutación aleatoria del 5% o 1% según el caso. Asimismo, se estableció un esquema de reproducción con el 50% de la población como progenitores por generación, un elitismo de 5 individuos y un límite máximo de 500 generaciones, incorporando criterios de parada temprana ante la consecución del fitness objetivo de 53.25 MW o la saturación del sistema tras 50 generaciones consecutivas sin mejoras significativas.

Las tres configuraciones analizadas se definieron de la siguiente manera:

- La Instancia 1 (la inicial) actuó como la línea de base o grupo de control del experimento, configurada con una población de **100 individuos** y una probabilidad de mutación del **5%**.
- La Instancia 2 (menor mutación) fue diseñada para evaluar el impacto de una **menor** tasa de exploración en el espacio de búsqueda, manteniendo la población en 100 individuos pero reduciendo la probabilidad de mutación al **1%**.
- La Instancia 3 (menor población) se orientó a medir el efecto de la **reducción** de la diversidad genética inicial y la carga computacional, disminuyendo la población a **50 individuos** y restituyendo la mutación al 5%.

Evaluación del Desempeño Generacional

En la totalidad de las ejecuciones realizadas para las tres instancias, el algoritmo convergió con éxito hacia el óptimo global de 53.25 MW, alcanzando una tasa de eficacia del 100% en todos los casos. El análisis comparativo de la velocidad de convergencia, medida en generaciones, permite entender la relevancia de cada parámetro en el proceso de optimización:

- La Instancia 1 (NORMAL) registró un promedio de **9.0 generaciones** por corrida, con una desviación estándar de 4.1 generaciones y una convergencia mínima registrada en la primera generación.
- La Instancia 2 (MUTACIÓN) presentó una aceleración en la convergencia generacional, con una media de **6.4 generaciones por corrida**, una desviación estándar de 2.7 generaciones y un mínimo de una generación.
- La Instancia 3 (POBLACIÓN) exhibió un comportamiento muy similar a la línea de base, con un promedio de **9.1 generaciones por corrida**, una desviación estándar de 3.2 generaciones y un mínimo de 2 generaciones.

Evaluación del Desempeño Temporal


El estudio del tiempo de ejecución permite validar la eficiencia computacional del algoritmo frente a las modificaciones en la población y la tasa de mutación a lo largo de las treinta corridas de cada instancia. Se registró un tiempo medio de procesamiento de 0.186 segundos para la Instancia 1, de 0.124 segundos para la Instancia 2 y de 0.090 segundos para la Instancia 3.

Estos datos confirman de manera empírica que el costo computacional dominante del algoritmo reside en el tamaño de la población procesada por cada ciclo evolutivo (la carga que representa evaluar la función de aptitud sobre cada individuo) antes que en la

cantidad total de generaciones ejecutadas. Al comparar la Instancia 1 y la Instancia 3, se observa que a pesar de requerir un número de generaciones promedio prácticamente idéntico (9.0 frente a 9.1), el tiempo medio de procesamiento se contrajo a menos de la mitad (de 0.186 a 0.090 segundos) debido a que cada generación evalúa únicamente 50 individuos en lugar de 100. Por su parte, la variación de la mutación en la Instancia 2 demostró que este operador influye indirectamente en el rendimiento temporal al agilizar la convergencia generacional y reducir el tiempo total acumulado por corrida a un promedio de 0.124 segundos. En todas las instancias evaluadas, los tiempos se mantuvieron dentro de márgenes operativos reducidos, demostrando una alta capacidad de respuesta del sistema.

Gráficos Estadísticos

Boxplot




El análisis comparativo del diagrama de cajas permite visualizar de manera directa la dispersión temporal y el comportamiento estocástico de cada configuración. En la Instancia 1 (parámetros base), se observa la caja más alargada y con los bigotes más extendidos del conjunto. Esta mayor amplitud del rango intercuartílico indica una alta variabilidad en los tiempos de ejecución, reflejando visualmente su mayor desviación estándar. Geométricamente, una caja ancha y bigotes largos implican que, aunque el algoritmo es efectivo, su costo temporal oscila significativamente de una corrida a otra dependiendo de la aleatoriedad en las operaciones de cruce y mutación.

Al observar la Instancia 2 (tasa de mutación reducida al 1%), la caja se ubica más abajo en el eje temporal y reduce considerablemente su altura. Esta compresión demuestra que la gran mayoría de las ejecuciones se concentran en una ventana de tiempo más estrecha y rápida. Sin embargo, el gráfico expone claramente un valor atípico (outlier) por encima del bigote superior. Este punto aislado revela visualmente un riesgo característico de la baja mutación: aunque mejora la velocidad general al proteger los buenos cromosomas, expone al algoritmo a estancamientos esporádicos en óptimos locales, lo que dispara el tiempo de procesamiento en ejecuciones puntuales.

Finalmente, la Instancia 3 (población de 50 individuos) exhibe la caja más estrecha, compacta y cercana al límite inferior del gráfico. Una caja con estas características, combinada con bigotes sumamente cortos, es el indicador visual definitivo de una altísima previsibilidad: el sistema requiere sistemáticamente el mismo tiempo para resolver el problema en casi todas las iteraciones. Esto corrobora empíricamente que reducir el tamaño poblacional disminuye drásticamente la cantidad de cálculos requeridos por la función de fitness. Como resultado, no solo se logra el menor costo temporal absoluto, sino que se obtiene la configuración computacionalmente más estable, eficiente y predecible de todo el experimento.

Gráficos Comparativos de Generaciones y Tiempo



Para complementar el análisis estadístico previo, el gráfico comparativo por ejecución ilustra de manera directa el comportamiento dinámico de las tres configuraciones. En el panel superior (Generaciones), se evidencia visualmente la alta volatilidad de la configuración base (línea azul), con picos pronunciados que contrastan con la trayectoria más baja y contenida de la Instancia 2 (línea verde), reafirmando su mayor eficiencia evolutiva. Por su parte, el panel inferior (Tiempo) resulta definitivo respecto al costo computacional: aunque la Instancia 3 (línea amarilla) presenta oscilaciones en sus generaciones, su curva de tiempo de cómputo se mantiene de forma consistente en la franja inferior a lo largo de las 30 ejecuciones. Esto corrobora que, para este diseño espacial, la reducción poblacional es la estrategia técnica más efectiva para agilizar el procesamiento sin comprometer el hallazgo del óptimo global.

Discusión

La obtención consistente del valor óptimo de 53.25 a través de las diferentes configuraciones del set experimental ratifica que el problema de optimización de parques eólicos, bajo la representación matemática adoptada, presenta una alta densidad de soluciones factibles. Dado que **la tasa de ocupación de la grilla es de apenas el 6.25%** (25 celdas ocupadas sobre 400 posibles), la probabilidad de identificar configuraciones carentes de solapamiento de estelas es elevada. Esto permite que el algoritmo eluda la necesidad de una búsqueda exhaustiva en el vasto espacio combinatorio.

La variabilidad observada, reflejada en las desviaciones estándar de 4.1, 2.7 y 3.2 generaciones respectivamente, demuestra que el éxito del proceso no recae exclusivamente en una fuerza bruta poblacional masiva, sino en la efectividad estructural de los operadores genéticos. La selección por torneo y el cruce de dos puntos probaron ser mecanismos idóneos para **refinar las posiciones iniciales sin destruir la información espacial**. Asimismo, el análisis de sensibilidad (cambio de parámetros) evidenció que una reducción en el tamaño de la población impacta directamente en la disminución del tiempo de cómputo, producto de una menor carga de procesamiento en la función de evaluación. Por su parte, la reducción de la tasa de mutación aceleró el proceso evolutivo (convergencia), en concordancia con los fundamentos teóricos que dictan que una menor disrupción protege la herencia de los bloques genéticos de alta aptitud.

Cabe destacar, que el éxito de estas configuraciones (población reducida y baja mutación) **depende directamente de las características de este problema**. En problemas de optimización con restricciones espaciales más severas o con funciones objetivo más específicas, operar con una población excesivamente pequeña comprometería la diversidad genética inicial, induciendo estancamientos tempranos. De igual manera, una tasa de mutación mínima podría provocar una convergencia prematura hacia óptimos locales, imposibilitando el hallazgo del óptimo global. En este sentido, la alta eficiencia computacional lograda en los experimentos finales es viable únicamente porque el amplio margen de maniobra de la grilla compensa la reducción en la capacidad de exploración del algoritmo.

Conclusión

El desarrollo e implementación del algoritmo genético para la optimización del diseño de parques eólicos permitió validar la eficacia de los enfoques metaheurísticos en espacios de búsqueda masivos y altamente no lineales. Los resultados experimentales obtenidos a lo largo de las 90 ejecuciones independientes demostraron una efectividad del 100% en la consecución del óptimo global de 53.25MW, lo que confirma de manera empírica la idoneidad de la representación cromosómica entera adoptada, la calibración de los hiperparámetros iniciales y las hipótesis planteada respecto a la alta densidad de soluciones factibles en el espacio mapeado.

El análisis de parámetros por instancias proporcionó conclusiones fundamentales sobre la dinámica de los componentes evolutivos, reforzando de forma práctica los fundamentos teóricos. En primer lugar, se constató que el tamaño **poblacional** ejerce una influencia directa y dominante sobre el **tiempo físico de ejecución**, pero no condiciona severamente la cantidad de generaciones requeridas para la convergencia, de este modo,

reducir la población a la mitad demostró una alta eficiencia temporal al disminuir la carga de procesamiento en la función de aptitud sin comprometer la calidad de las soluciones finales. En segundo lugar, la disminución de la tasa de **mutación** al 1% evidenció una **aceleración en la convergencia** generacional, lo que sugiere que, para las características morfológicas de **este problema particular**, una estrategia orientada a la explotación temprana de bloques genéticos favorables optimiza significativamente el proceso sin desestabilizar la población.

En síntesis, el modelo propuesto exhibe una escalabilidad favorable, estabilidad estadística y robustez computacional. Por lo que se cree que la combinación estratégica de los operadores de selección por torneo, cruce de dos puntos y preservación de élite mitiga eficazmente el riesgo de confinamiento en óptimos locales, lo que proporcionó configuraciones óptimas en tiempos de procesamiento consistentemente inferiores a los doscientos milisegundos.

Con estos resultados, las líneas de trabajo futuro podrían orientarse hacia una mayor optimización de los recursos mediante la acotación de los rangos iniciales de población y mutación, lo que consecuentemente permitiría reducir tanto el umbral de saturación por estabilidad como el límite de generaciones totales del algoritmo. Asimismo, resultaría fructífero someter la arquitectura propuesta a escenarios de diseño con restricciones espaciales más severas o funciones más complejas para evaluar los límites de su capacidad exploratoria. No obstante, el experimento realizado constituye un sólido acercamiento práctico al desarrollo de algoritmos genéticos y ratifica con éxito los conceptos teóricos abordados en la asignatura.