

Laboratorio 4 - Aprendizaje Automático

1. Fundamentación

Este laboratorio integra los contenidos de aprendizaje automatico de la asignatura: aprendizaje supervisado, no supervisado, métricas de evaluación, árboles de decision, KNN, Random Forest, clustering, PCA y analisis de resultados. La actividad esta pensada para realizarse en grupos, pero con una evaluacion individual posterior en Moodle.

2. Objetivos

- Diferenciar problemas supervisados y no supervisados.
- Realizar analisis exploratorio de datos antes de entrenar modelos.
- Entrenar y comparar distintos algoritmos supervisados.
- Evaluar modelos mediante accuracy, precision, recall, F1 y matriz de confusion.
- Optimizar hiperparametros mediante validacion cruzada.
- Aplicar clustering con KMeans.
- Analizar metricas internas de clustering: inercia y silhouette.
- Usar PCA para visualizacion e interpretacion de datos multidimensionales.
- Elaborar conclusiones tecnicas justificadas a partir de resultados.

3. Modalidad de trabajo

Aspecto	Detalle
Tipo de Entrega	Grupal, con informe tecnico y codigo Python ejecutable.
Evaluacion posterior	Quiz individual Moodle orientado a conceptos, interpretacion de metricas y toma de decisiones.
Herramientas	Python, pandas, numpy, matplotlib, scikit-learn.
Entregables	Notebook o script, informe PDF/Word, graficos y conclusiones.

4. Problema A - Caso supervisado

Se trabajará con el dataset Breast Cancer Wisconsin incluido en scikit-learn. El objetivo es predecir si una muestra corresponde a una clase maligna o benigna a partir de variables numericas calculadas sobre características de nucleos celulares.

4.1 Actividades obligatorias

1. Cargar el dataset y describir cantidad de registros, variables y clases.
2. Analizar distribucion de clases e identificar si existe desbalance.
3. Calcular estadisticos descriptivos de las variables.
4. Separar entrenamiento y prueba usando train_test_split con stratify.
5. Entrenar al menos cinco modelos: Regresion Logistica, Arbol de Decision, Random Forest y Red Neuronal Multicapa.
6. Comparar accuracy, precision, recall y F1.
7. Mostrar matriz de confusion del mejor modelo.
8. Optimizar hiperparametros con GridSearchCV.
9. Analizar importancia de variables en Random Forest.

10. Entrenar un árbol interpretable reducido y explicar sus reglas principales.

4.2 Preguntas conceptuales

- ¿Qué métrica priorizaría si el costo de no detectar un caso maligno fuera muy alto?
- ¿Qué diferencia observa entre el desempeño base y el desempeño optimizado?
- ¿Qué algoritmo fue más interpretable? ¿Qué algoritmo obtuvo mejor desempeño?
- ¿Por qué algunos algoritmos requieren escalado de variables y otros no?
- ¿Qué signos de sobreajuste o subajuste encontró?

5. Problema B - Caso no supervisado

Se trabajará con el dataset Iris incluido en scikit-learn. En esta parte se ignorarán las etiquetas durante el entrenamiento y se buscará agrupar observaciones por similitud. Las etiquetas reales solo se usarán al final para comparar resultados.

5.1 Actividades obligatorias

11. Cargar el dataset Iris y describir variables.
12. Estandarizar los datos.
13. Aplicar PCA a dos componentes para visualizar.
14. Entrenar KMeans con k entre 2 y 7.
15. Analizar inercia y método del codo.
16. Analizar silhouette para cada k.
17. Visualizar clusters en el plano PCA.
18. Explicar diferencia entre métricas internas y métricas externas.

6. Análisis esperado de resultados

En el caso supervisado, se esperan que los modelos como Árboles, Regresión Logística y Random Forest obtengan desempeños altos porque el dataset contiene variables numéricas informativas. La selección de la mejor métrica debe depender del objetivo: en problemas médicos, el recall de la clase crítica suele ser especialmente relevante.

En el caso no supervisado, KMeans requiere elegir k y tiende a formar clusters aproximadamente esféricos. PCA no entrena un clasificador: se usa para reducir dimensionalidad y visualizar estructuras.