

Segundo proyecto evaluativo

Aprendizaje automático - Supervisado y No supervisado

Inteligencia Artificial 2026

Alumnos:

Botha Ana Josefina

Lang Carlos

Vidal Facundo

Zarate Guido Mateo Benjamin



INTRODUCCIÓN

El presente proyecto aborda los dos paradigmas fundamentales del Aprendizaje Automático: el enfoque supervisado y el no supervisado. A través de un análisis experimental implementado en Python con scikit-learn, se trabaja sobre dos datasets de referencia: Breast Cancer Wisconsin e Iris, comparando algoritmos de diversa naturaleza en términos de generalización, complejidad e interpretabilidad.

En el caso supervisado, el problema de clasificación binaria sobre datos médicos pone en foco no solo el desempeño de los modelos, sino también la elección de métricas que reflejen el costo real de cada tipo de error. En el caso no supervisado, el objetivo es descubrir estructuras sin recurrir a etiquetas, evaluando la calidad del agrupamiento mediante métricas internas y apoyándose en PCA para la visualización e interpretación de los resultados.

En conjunto, la experiencia busca consolidar un criterio técnico para seleccionar, evaluar y justificar modelos de Machine Learning conectando las métricas matemáticas con el contexto y las necesidades del problema de aplicación.

APRENDIZAJE SUPERVISADO (4.1)

1. Cargar el dataset y describir cantidad de registros, variables y clases

Se utilizó el dataset Breast Cancer Wisconsin, disponible en la librería sklearn.datasets.

Características del dataset:

- **Cantidad de registros:** 569
- **Cantidad de variables (features):** 30
- **Cantidad de clases:** 2 (clasificación binaria)
 - malignant (maligno) : 212 registros
 - benign (benigno): 357 registros

Las variables corresponden a medidas computadas a partir de imágenes digitalizadas de biopsias de masa mamaria, incluyendo características como radio, textura, perímetro, área, suavidad, compacidad, concavidad, simetría y dimensión fractal, calculadas como media, error estándar y peor valor para cada núcleo celular.

2. Analizar distribución de clases e identificar si existe desbalance.

Clase	Registros	Proporción
Beningno	357	62.74%
Maligno	212	37.26%

La relación mayoritaria / minoritaria 1.68:1, lo que indica que la clase benigna supera en casi el doble a la maligna. Si bien este desbalance no es severo, puede influir al sesgo de los clasificadores, que pueden tender a predecir con mayor frecuencia la clase mayoritaria.

3. Calcular estadísticos descriptivos de las variables.



Medidas de tendencia central y dispersión:

Variable	Media	Mediana	Desvío Estándar
Mean Texture	19.29	18.84	4.30
Mean Perimeter	91.97	86.24	24.30
Mean Area	654.89	551.10	351.91
Mean Smoothness	0.10	0.10	0.01
Mean Compactness	0.10	0.09	0.05
Worst Compactness	0.25	0.21	0.16
Worst Fractal Dimension	0.08	0.08	0.02

Asimetría (skewness):

Variable	Asimetría
Mean Texture	0.65
Mean Perimeter	0.99
Mean Area	1.65
Mean Compactness	1.19
Mean Smoothness	0.46
Worst Compactness	1.47
Worst Fractal Dimension	1.66

Variables como mean área y worst fractal dimension presentan asimetría positiva considerable (>1.5), indicando la presencia de valores extremos hacia la derecha de la distribución.



Outliers detectados (Método IQR):

Variable	Cantidad de Outliers
Mean Texture	7
Mean Perimeter	13
Mean Area	25
Mean Compactness	16
Mean Smoothness	6
Worst Compactness	16
Worst Fractal Dimension	24

De las variables analizadas Mean Área y Worst Fractal Dimension concentran la mayor cantidad de valores atípicos lo cual es consistente con su alta asimetría observada.

4. Separar entrenamiento y prueba (usando train_test_split con stratify).

El dataset fue dividido utilizando train_test_split con el parámetro stratify=y, garantizando que la proporción de clases se mantenga en ambos subconjuntos.

Conjunto	Registros	Proporción
Total	569	100%
Entrenamiento	455	80%
Prueba	114	20%

5. Entrenar al menos cinco modelos: Regresión Logística, KNN, Árbol de Decisión, Random Forest y Red Neuronal Multicapa.

Se entrenaron cinco modelos de clasificación supervisada sobre el conjunto de entrenamiento y se evaluó su accuracy sobre el conjunto de prueba.

Modelo	Accuracy
Regresión Logística	98.25% (mejor)
KNN	95.61%


Random Forest	95.61%
Red Neuronal (MLP)	94.74%
Árbol de Decisión	91.23%

6. Comparación de Accuracy, precisión, recall y F1

Modelo	Accuracy	Precisión	Recall	F1
Regresión Logística	0.9825	0.9861	0.9861	0.9861
Árbol de Decisión	0.9123	0.9559	0.9028	0.9286
Random Forest	0.9561	0.9589	0.9722	0.9655
Red Neuronal (MLP)	0.9649	0.9857	0.9583	0.9718
KNN	0.9561	0.9589	0.9722	0.9655

Se observa que el Modelo de Regresión Logística aparece como el mejor en todos los casos.

7. Matriz de Confusión de Regresión Logística (Mejor Modelo)



Observamos en la Matriz de Confusión como la mayor cantidad de aciertos se ubica en la diagonal de la matriz, quedando solamente 1 caso como falso positivo (cuadrante inferior izquierdo) y un falso negativo (cuadrante superior derecho). Este último sería el error más grave.


8. Optimización de hiper parámetros con GridSearchCV

Optimizando el mejor modelo (Random Forest), obtenemos los siguientes resultados:

Mejores parámetros: {'max_depth': None, 'min_samples_split': 2, 'n_estimators': 200}

Mejor F1-Score CV: 0.9684

9. Análisis de importancia de Variables en el Modelo Random Forest




Observamos que las variables más significativas resultantes son, en orden de importancia: worst perimeter (peor perímetro), worst area (peor área), worst concave points (peores puntos cóncavos), mean concave points (puntos cóncavos medios) , worst radius (peor radio). Esto muestra que los algoritmos están dando prioridad a los valores más extremos.

10. Árbol de decisión reducido

Se construye un árbol de decisión reducido a dos niveles:

Estructura del Árbol Reducido



Observamos en el árbol de decisión reducido, que la variable elegida como nodo raíz es el “worst radius”, la cual suponemos como la variable con más ganancia de información, lo que determina la principal característica a observar para el diagnóstico. Una vez evaluado esto, el modelo se apoya en las variables worst concave points y texture error para determinar el diagnóstico final.

Las Reglas a aplicar serían:

1. Caso Benigno: worst radius ≤ 16.795 y worst concave point ≤ 0.136
2. Caso Maligno: worst radius ≤ 16.795 y worst concave point > 0.136
3. Caso Benigno: worst radius > 16.795 y worst concave point ≤ 0.136
4. Caso Maligno: worst radius > 16.795 y worst concave point > 0.136

Preguntas conceptuales (4.2)

- ¿Qué métrica priorizaría si el costo de no detectar un caso maligno fuera muy alto?

Se debe priorizar el Recall (también conocido como Sensibilidad). En este contexto médico, el error más grave es el Falso Negativo (clasificar como benigno un tumor que en realidad es maligno). Al maximizar el Recall, nos aseguramos de que el modelo identifique correctamente la mayor proporción posible de los casos malignos reales, minimizando así el riesgo de dejar a un paciente sin tratamiento.

- ¿Qué diferencia observa entre el desempeño base y el desempeño optimizado?

En el caso del modelo Random Forest, la diferencia es bastante marginal. El modelo base ya presentaba un desempeño muy bueno con un F1-Score de 0.9655. Al aplicar GridSearchCV, el F1-Score resultante por validación cruzada fue de 0.9684. Esto indica que los hiperparámetros por defecto de Random Forest ya eran adecuados para este conjunto de datos, logrando una ganancia de rendimiento muy leve tras la optimización.

- ¿Qué algoritmo fue más interpretable? ¿Qué algoritmo obtuvo mejor desempeño?

El algoritmo más interpretable fue el Árbol de Decisión, ya que su estructura permite extraer reglas lógicas de diagnóstico transparentes y fáciles de comprender.

Por otro lado, el algoritmo con mejor desempeño fue la Regresión Logística, el cual lideró la tabla con un Accuracy del 98.25% y un F1-Score de 0.9861.

- ¿Por qué algunos algoritmos requieren escalado de variables y otros no?

Los algoritmos basados en cálculos de distancia (como KNN) o en la optimización por descenso de gradiente (como las Redes Neuronales y la Regresión Logística) requieren que los datos estén en la misma escala. Si no se estandarizan, las variables con rangos numéricos más grandes (como el área) dominarían artificialmente sobre las variables con rangos pequeños (como la suavidad).

Por el contrario, los modelos basados en árboles (Árboles de Decisión y Random Forest) no requieren escalado porque toman sus decisiones dividiendo el espacio de datos basándose en cortes umbrales sobre variables individuales, lo cual es invariante a la escala matemática de los datos.

- ¿Qué signos de sobreajuste o subajuste encuentro?

Para analizar esto, primero debemos definir ambos conceptos:

Subajuste (Underfitting): Ocurre cuando el modelo es demasiado simple para capturar los patrones de los datos, mostrando un bajo rendimiento tanto en el entrenamiento como en la prueba.

Sobreajuste (Overfitting): Ocurre cuando el modelo memoriza el conjunto de entrenamiento (logrando resultados casi perfectos allí), pero pierde capacidad de generalización y falla frente a datos nuevos en la fase de prueba.

Analizando nuestros resultados, no se observan signos de subajuste, ya que la mayoría de los modelos capturaron bien la complejidad geométrica de los tumores, superando el 94% de efectividad en la prueba. Respecto al sobreajuste, el Árbol de Decisión individual obtuvo el rendimiento más bajo (91.23%). Esto es normal en los árboles que crecen sin restricciones de profundidad (memorizan el dataset de entrenamiento), lo que provoca que generalicen peor ante muestras nuevas en comparación con métodos promediados más robustos como el Random Forest.

APRENDIZAJE NO SUPERVISADO (5.1)

11. Cargar el dataset Iris y describir variables.

Resultados obtenidos:

```
Cantidad de registros : 150
Cantidad de variables : 4
Variables              : ['sepal length (cm)', 'sepal width (cm)',
                          'petal length (cm)', 'petal width (cm)']
Clases reales          : [np.str_('setosa'), np.str_('versicolor'),
                          np.str_('virginica')]
```


El dataset arroja un resultado con 150 registros correspondiente a 150 tipos de flores, 4 variables numéricas: largo y ancho del sépalo, y largo y ancho del pétalo, correspondientes a las medidas en centímetros.

```
target
setosa      50
versicolor  50
virginica    50
Name: count, dtype: int64
```


Las observaciones pertenecen a 3 grupos de especies: Setosa, Versicolor y Virginica, con 50 muestras por cada especie. Estas etiquetas se guardan al final para usar como referencia.

12. Estandarizar los datos


Como pide el enunciado, estandarizamos los datos. Se aplicó StandardScaler, que deja cada variable con media 0 y desvío 1, para garantizar que las 4 características sean equitativas. Esto nos va a permitir poder realizar PCA con los datos.

13. Aplicar PCA a dos componentes para visualizar.

Se aplicó PCA reduciendo de 4 a 2 dimensiones. Aplicamos pesos (loadings) para indicar con cuanta fuerza entra cada variable original en cada componente. PC1 Está dominada por las variables del pétalo (largo y ancho) y por el largo del sépalo, todas con el mismo signo. Esto separa flores grandes de las chicas. PC2 está dominada por el ancho del sépalo.



Versión diferenciada por especie real. Solo se utiliza como referencia visual. Las etiquetas no participan del entrenamiento, se usan formalmente al final.




Actividades 14 a 16:

- Entrenar KMeans con k entre 2 y 7.
- Analizar inercia y método del codo
- Analizar silhouette para cada k.

Se entrenó un modelo KMeans para cada k entre 2 y 7, registrando la inercia y el silhouette de cada configuración. La inercia (suma de distancias al cuadrado a cada centroide) decrece siempre al aumentar k, por lo que el criterio es localizar el codo, donde la mejora se vuelve marginal. El silhouette mide qué tan compactos y separados quedan los grupos, en un rango de -1 a 1.


	k	inercia	silhouette
0	2	222.36	0.5818
1	3	139.82	0.4599
2	4	114.09	0.3869
3	5	90.93	0.3459
4	6	81.54	0.3171
5	7	72.63	0.3202



El codo se ubica en $k = 3$, que coincide con la cantidad real de especies.

Actividad 17 Visualizar clusters en el plano PCA.

Se graficaron los clusters sobre las dos componentes principales para $k = 3$ (método del codo y estructura real) y $k = 2$ (mejor silhouette), incluyendo los centroides proyectados. Con $k = 3$ se recupera la separación en 3 grupos, con $k = 2$ estos grupos quedan unidos.



Actividad 18 Métricas: internas y externas

- **Métricas Internas:** Son aquellas que evalúan la calidad de los grupos formados utilizando únicamente la información intrínseca de los datos, operando de manera completamente no supervisada. Se basan principalmente en dos criterios geométricos: la cohesión (buscan que los elementos de un mismo cluster estén lo más cerca posible entre sí) y la separación (buscan que los distintos clusters estén amplia y claramente distanciados unos de otros). Ejemplos de esto son el Índice Silhouette y el Índice Davies-Bouldin.
- **Métricas Externas:** Son aquellas que evalúan el resultado del agrupamiento comparándolo con las etiquetas reales o clases verdaderas del problema (la estructura de referencia). Miden qué porcentaje de los clusters formados por el algoritmo coinciden realmente con las categorías preexistentes. Por ejemplo, en el dataset Iris, verificar si un cluster agrupó correctamente todas las flores de tipo setosa.

Las métricas internas son "ciegas" a las respuestas verdaderas y juzgan únicamente qué tan compactos y separados quedaron los grupos en el espacio de datos; son la herramienta a usar en problemas reales de clustering donde no conocemos las clases. En cambio, las métricas externas hacen "trampa", ya que utilizan las etiquetas reales al final del proceso para auditar si el algoritmo de verdad agrupó los elementos como en la realidad.

CONCLUSIONES

El desarrollo de este proyecto nos permitió consolidar de manera práctica los dos paradigmas de aprendizaje vistos: supervisado y no supervisado. A través de la experimentación con los conjuntos de datos de referencia, se logró comprender la causalidad del éxito del modelo, la cual depende de la correcta comparación de las variables, del tratamiento de los datos y de los conjuntos de entrenamiento/prueba.

En la sección supervisada, la experiencia con el diagnóstico clínico evidenció la importancia de alinear las métricas de evaluación, con el impacto real del problema en un entorno de aplicación. Los datos al ser más realistas, salían de la forma normal a la que estábamos acostumbrados, promoviendo el análisis y criterio al trabajar con los mismos. Y al ser un contexto médico, se comprendió las prioridades, lo que obliga a poner en foco al Recall sobre la exactitud general para asegurar la detección de casos graves. También se pudo observar la comparación entre Regresión Logística y el Árbol de Decisión, que nos mostró el balance entre el máximo desempeño y la transparencia o interpretabilidad de las reglas de decisión.

Por otro lado, la sección no supervisada, proporcionó un aprendizaje valioso al explorar y descubrir las estructuras de datos sin “tener” las etiquetas previas, promoviendo el análisis propio y crítico de los resultados obtenidos en cada experimentación. Se comprendió la importancia de estandarizar para posteriormente reducir las dimensiones de las variables mediante PCA, lo cual nos permite mitigar las diferencias de escala (importantísimo para no cometer errores en la comparación) y hacer visibles las agrupaciones en un plano interpretable. Así mismo, se pudo experimentar y corroborar la funcionalidad de los métodos dados, como el índice de Silhouette o el método del codo, que nos permite encontrar y justificar matemáticamente la estructura óptima de agrupamiento, que coincide o asemeja precisamente con la realidad de las categorías presentadas en el problema.